

Corpus de référence pour les SGBDR, ACID, l'algèbre relationnelle, la normalisation, les statistiques et les structures de recherche

Méthode de sélection

Le corpus ci-dessous sépare volontairement deux couches. La première est le **socle durable**, c'est-à-dire les textes qui définissent encore aujourd'hui le vocabulaire, les propriétés formelles et les garanties d'implémentation des systèmes relationnels. La seconde est le **front moderne 2024-2026**, utile pour le contrepoint, le contrôle croisé et l'évaluation de ce qui change réellement dans la pratique contemporaine. Pour ce besoin, les sources les plus solides sont les articles fondateurs, les grandes synthèses académiques, les revues à comité de lecture, les actes de conférences majeures, et les retrospectives qui confrontent la théorie aux moteurs réels. ¹

Le point important pour votre objectif est le suivant : il ne faut pas mélanger **ce qui est démontré depuis des décennies** avec **ce qui est prometteur mais encore contingent au workload, à la distribution des données, au matériel ou aux hypothèses expérimentales**. Dans ce rapport, je marque donc explicitement ce qui relève du consensus scientifique, ce qui relève d'une pratique industrielle très consolidée, et ce qui appartient encore à la zone de recherche active. ²

Socle relationnel

Le socle commence avec Edgar F. Codd ³ chez IBM ⁴. Son article de 1970 pose le modèle relationnel comme une application de la théorie des relations à des "large shared data banks", introduit l'idée d'une normal form et d'un langage d'accès de haut niveau, et déplace le centre de gravité depuis la navigation physique vers la description logique des données. Deux ans plus tard, son travail sur la "relational completeness" donne une base formelle à la puissance expressive des sous-langages relationnels et à la traduction du calcul vers l'algèbre. Pour une formulation encore robuste aujourd'hui, *Foundations of Databases* reste l'un des meilleurs textes d'unification théorique. ⁵

Sur le plan opérationnel, le second pilier est **System R**. L'article de Selinger et ses co-auteurs montre pourquoi SQL et les langages non procéduraux ont effectivement besoin d'un optimiseur basé sur les coûts : la requête décrit le résultat désiré, pas le chemin d'accès. Ce texte est toujours central parce qu'il fixe le triptyque qui structure encore les optimiseurs modernes : **estimation de cardinalité, modèle de coût, énumération de plans**. La littérature récente confirme d'ailleurs que, malgré toutes les tentatives de remplacement, le modèle relationnel et SQL restent le choix dominant pour les SGBD, les nouveautés s'intégrant surtout comme extensions, pas comme substitution totale. ⁶

Pour l'algèbre relationnelle, il faut être rigoureux sur un point : la littérature sérieuse ne parle pas d'une liste "folklorique" de recettes, mais d'**équivalences sémantiques**. En pratique, les lois fondamentales à maîtriser sont la décomposition et la commutativité des sélections, l'idempotence des projections, les réordonnancements de jointures quand les préconditions sémantiques sont satisfaites, et le *pushdown* des opérateurs qui réduit tôt la taille intermédiaire des relations. Cette idée d'"expressions différentes mais résultat identique" est toujours au cœur de l'optimisation. Le fait même que des travaux récents

comme *WeTune* cherchent encore à **découvrir et vérifier automatiquement** de nouvelles règles de réécriture montre que cette base algébrique n'est pas historique au sens mort du terme : elle reste active, testable et perfectible. ⁷

La conclusion rigoureuse pour cette section est simple : si vous voulez un noyau théorique durable, il faut retenir ensemble **modèle relationnel, complétude relationnelle, algèbre relationnelle, calcul relationnel**, puis **optimisation basée sur les coûts**. Ce bloc est beaucoup plus stable que les modes successives autour des systèmes “schema-last”, des moteurs hybrides ou des composants appris. ⁸

Transactions, ACID et contrôle de concurrence

La notion moderne de transaction est fixée très tôt par Jim Gray ⁹ : une transaction est une transformation d'état qui doit préserver l'atomicité, la durabilité et la correction de la transformation. Le cadre ACID est ensuite formulé de manière canonique dans le grand article de Härder et Reuter, qui présente ces quatre propriétés comme le test qualitatif majeur d'un système transactionnel. Cette source reste hautement prioritaire, non pas pour des slogans, mais parce qu'elle relie proprement le concept de transaction, les modes de terminaison, la récupération et la qualité du système. ¹⁰

Si l'on descend d'un niveau, la propriété réellement décisive en concurrence n'est pas “ACID” pris comme mot-valise, mais la manière dont un système réalise l'**isolation** et traite les **anomalies**. Le texte d'Eswaran, Gray, Lorie et Traiger sur les *predicate locks* est capital parce qu'il rattache la cohérence concurrente à la discipline de verrouillage en deux phases et met directement sur la table le problème des **phantoms**. Puis la critique de 1995 publiée par Microsoft Research ¹¹ montre que les phénomènes d'ANSI SQL-92 ne caractérisent pas correctement plusieurs niveaux d'isolation populaires ; elle clarifie les ambiguïtés et introduit de meilleurs phénomènes de caractérisation. La thèse d'Adya poursuit ce travail et fournit des définitions généralisées, portables et plus propres formellement. ¹²

Une conséquence pratique importante est qu'il ne faut jamais traiter “snapshot isolation” comme synonyme automatique de sérialisabilité. La critique de 1995 explicite déjà la zone grise, et l'article sur **Serializable Snapshot Isolation** dans PostgreSQL montre pourquoi une implémentation de niveau sérialisable fondée sur SSI a été nécessaire : elle offre une vraie sérialisabilité avec une performance souvent proche de snapshot isolation, tout en évitant les blocages du 2PL classique sur certains workloads. Pour un DBA ou un architecte, c'est un point de contrôle fondamental : la *label* d'isolation ne suffit pas ; il faut comprendre le modèle d'anomalies sous-jacent. ¹³

Pour la récupération après panne, **ARIES** reste la référence incontournable. Son apport n'est pas seulement le *write-ahead logging* ; c'est le fait de combiner journalisation, verrous de granularité fine et *partial rollbacks* dans un schéma robuste qui a irrigué la conception réelle des grands moteurs. Son prolongement **ARIES/IM** pour les indexes montre en plus comment garantir sérialisabilité et forte concurrence sur des B+-trees transactionnels. Historiquement, c'est l'un des endroits où la théorie transactionnelle rencontre vraiment l'ingénierie des structures d'accès. ¹⁴

Du côté moderne, le déterminisme transactionnel distribué ne relève plus de la curiosité. **Calvin** a montré qu'un ordonnancement déterministe pouvait rendre les transactions distribuées plus scalables en réduisant les coûts de contention normalement associés aux transactions multi-partitions. Mais il faut rester nuancé : les évaluations récentes des algorithmes de *deterministic concurrency control* et les travaux 2025-2026 sur les bases déterministes montrent que ce champ reste très actif et très dépendant du contexte applicatif. Autrement dit : c'est sérieux, mais ce n'est pas un remplaçant universel du transactionnel classique. ¹⁵

Dépendances, normalisation, cardinalité et granularité

Sur la normalisation, le noyau réellement fiable reste celui formé par Codd, Bernstein et Ronald Fagin ¹⁶. Le texte de Codd sur la *further normalization* explicite très clairement les objectifs : supprimer les dépendances d'insertion, de mise à jour et de suppression indésirables, augmenter la durée de vie des programmes applicatifs, et rendre le schéma moins dépendant des statistiques de requêtes changeantes. L'article de Bernstein est ensuite fondamental pour relier les dépendances fonctionnelles à une **synthèse algorithmique** vers des schémas en 3NF. Puis Fagin étend l'édifice avec les dépendances multivaluées, la 4NF, et plus tard la DK/NF. ¹⁷

Le point à conserver sans approximation est celui-ci : la normalisation sérieuse n'est pas une histoire de "formes normales pour l'examen", mais une théorie des **dépendances** et des **décompositions**. La 4NF de Fagin est importante parce qu'elle montre que les dépendances multivaluées généralisent les dépendances fonctionnelles et qu'un schéma peut toujours être décomposé en 4NF **sans perte d'information**. La DK/NF est importante parce qu'elle pousse le raisonnement jusqu'à l'idée qu'un schéma n'a plus d'anomalies d'insertion ou de suppression si toutes ses contraintes pertinentes sont réductibles aux domaines et aux clés. Pour un travail d'architecture, c'est un excellent repère conceptuel : plus on monte, plus on gagne en pureté sémantique, mais au prix d'exigences de modélisation souvent plus difficiles à soutenir en production. ¹⁸

Le terme **cardinalité** mérite une mise au point, car il recouvre dans votre périmètre **deux objets différents**. En modélisation conceptuelle, les contraintes de cardinalité expriment des bornes inférieures et supérieures de participation à un rôle ou à une relation ; elles sont un morceau formel de la sémantique métier. En optimisation de requêtes, la cardinalité désigne le **nombre de tuples** attendu à la sortie d'un opérateur, et devient une variable statistique cruciale. Ces deux sens doivent être tenus séparés, sinon les discussions sur la "cardinalité" deviennent vite ambiguës. ¹⁹

La **granularité**, elle, ne vient pas du cœur de l'algèbre relationnelle mais des modèles analytiques et décisionnels. Le principe le plus solide est celui du **grain** : une ligne de table de faits doit représenter exactement un événement de mesure bien défini, et seules les mesures compatibles avec ce grain sont admises. La littérature OLAP ajoute que l'agrégation correcte n'est pas automatique : la *summarizability* impose des conditions structurelles sous peine de produire des conclusions ou décisions erronées. Pour tout système analytique sérieux, la granularité doit donc être déclarée explicitement avant même de parler de métriques, d'index ou de cubes. ²⁰

Statistiques, prédiction, poids et déterminisme

Dans un SGBDR, la statistique n'est pas un appendice ; elle fait partie du moteur. La synthèse de 2021 sur l'optimiseur cost-based rappelle que presque tous les SGBD actuels reposent sur ce modèle et que la **cardinalité** y joue un rôle crucial. Les erreurs d'estimation de cardinalité, les limites du modèle de coût et l'énormité de l'espace de plans empêchent l'optimiseur de trouver un plan optimal raisonnablement vite sur les requêtes complexes. La rétrospective de 2025 sur *How Good Are Query Optimizers, Really?* va dans le même sens : les erreurs de cardinalité sont répandues et souvent le facteur dominant derrière les mauvais plans, beaucoup plus que la seule énumération ou le seul coût. ²¹

Du côté des techniques éprouvées, les **histogrammes** restent un socle très important. L'article de Poosala et al. de 1996 est encore fréquemment cité parce qu'il systématise les dimensions de conception des histogrammes et montre empiriquement quels choix fonctionnent le mieux pour l'estimation de sélectivité de prédicats de plage. En pratique, cela signifie qu'avant d'ajouter des

composants “learned”, il faut déjà comprendre maîtriser : distributions, distinct counts, corrélations, échantillonnage, erreurs de q-error, et propagation des erreurs dans les plans. ²²

Le front moderne le plus sérieux concerne l'**estimation de cardinalité apprise**. L'étude approfondie de 2022 montre que le sujet mérite une analyse fine, pas seulement des annonces de gains. *AutoCE* insiste ensuite sur un point très important pour le croisement de sources : **aucun modèle unique n'est invincible** sur toutes les distributions de données, d'où l'idée de sélectionner adaptativement le meilleur estimateur. *PACE* ajoute un contrepoint essentiel en montrant que les estimateurs appris introduisent aussi une nouvelle surface d'attaque : des requêtes empoisonnées dans l'historique peuvent dégrader très fortement précision et performance. Enfin, le modèle CoDe de 2025 montre que le problème reste ouvert mais progresse encore sur le compromis précision/latence. Le bon niveau de prudence est donc celui-ci : les estimateurs appris sont une direction sérieuse, mais certainement pas un consensus finalisé. ²³

Votre demande mentionne aussi **prédiction, poids, prévisionnel et déterminisme** au sens large. Là encore, le meilleur corpus sépare les contextes. En prévision statistique générale, *Forecasting: Principles and Practice* reste un excellent texte d'assise. Les résultats de la compétition M4 sont un rappel salutaire : les méthodes les plus performantes sont souvent des **combinaisons** ou des hybrides majoritairement statistiques, et les approches purement ML n'y ont pas dominé. En 2026, les travaux sur l'agrégation probabiliste par *statistical depth* prolongent cette ligne en s'intéressant précisément à la combinaison robuste, aux poids implicites et à l'absence éventuelle d'historique de précision. C'est une bonne leçon méthodologique pour le monde des bases : les approches pondérées et les ensembles robustes sont souvent plus crédibles que la recherche d'un estimateur unique supposé universel. ²⁴

Sur le **déterminisme**, il faut distinguer deux choses. En analyse statistique, le déterminisme s'oppose aux modèles stochastiques. En systèmes de données, il désigne surtout le fait qu'un même ensemble d'entrées transactionnelles conduise au même résultat sérialisable. Les travaux récents sur le *deterministic concurrency control* conservent donc un intérêt très élevé pour les systèmes distribués, mais leur domaine d'excellence reste ciblé, pas universel. ²⁵

Structures de recherche et indexation

Le socle des structures d'accès sérieuses repose d'abord sur le **B-tree**. L'article de 1972 de Bayer et McCreight montre qu'on peut maintenir un index dynamique ordonné avec coûts de recherche, insertion et suppression proportionnels à un logarithme en base dépendante du périphérique, avec une utilisation de stockage d'au moins 50 %, souvent bien supérieure. C'est exactement le type de résultat que vous cherchez : mathématique, structurel, ancien, mais toujours absolument vivant dans les moteurs réels. ²⁶

Pour le **hachage dynamique**, deux références restent structurantes. *Extendible Hashing* garantit au plus deux défauts de page pour localiser une clé unique, avec une structure qui croît et décroît proprement avec la base. *Linear Hashing* poursuit la même logique d'adaptation dynamique de l'espace d'adressage, mais sans le coût conceptuel d'un doublement brutal du répertoire. Pour un architecte base de données, ces deux textes demeurent le meilleur contrepoint aux simplifications modernes sur les “hash indexes”. ²⁷

Pour les **arbres binaires de recherche**, le texte de Donald E. Knuth ²⁸ sur les *optimum binary search trees* reste la bonne entrée lorsqu'on veut raisonner en coût de recherche **pondéré** plutôt qu'en simple hauteur. Il relie directement probabilités d'accès, longueur de chemin pondérée et programmation

dynamique. C'est la source la plus pertinente de votre liste dès qu'on parle de recherche guidée par des fréquences, des poids ou des distributions non uniformes. ²⁹

Pour les **parcours**, l'article de Tarjan sur la recherche en profondeur et les algorithmes linéaires sur graphes reste une pierre d'angle. Il ne traite pas un index relationnel à lui seul, mais il fixe l'une des grandes méthodes de parcours algorithmiques utilisées partout où il faut explorer efficacement des structures orientées, des dépendances, des plans ou des graphes de précédence. C'est une excellente pièce de socle dès que l'on veut relier théorie des parcours et structures de recherche. ³⁰

Le prolongement moderne est celui des **learned indexes**. Le texte de Kraska et al. a eu un impact majeur parce qu'il reformule un index comme un modèle apprenant une correspondance entre clé et position. Les synthèses et évaluations récentes montrent néanmoins une image plus nuancée : certains indexes appris réduisent massivement la taille ou améliorent certaines recherches, mais leur avantage dépend énormément de la dimensionnalité, du type de requête, de l'évolutivité des données, des coûts de mise à jour et du matériel. Le papier théorique de 2026 sur les bornes inférieures va encore plus loin en rappelant que les limites de ces structures ne sont pas encore pleinement comprises, même quand elles marchent bien empiriquement. WALDEN, également en 2026, montre enfin que la prise en compte explicite des **poids de requête** et des fréquences d'accès peut fortement changer la qualité d'un index appris ; c'est précisément le type de pont entre "poids" et "recherche" que vous demandiez. ³¹

Corpus prioritaire, limites et livrable

Si je devais figer un **noyau de lecture prioritaire** pour construire une culture extrêmement solide, je retiendrais d'abord : Codd 1970 et 1972 ; Selinger 1979 ; Gray 1981 ; Härder-Reuter 1983 ; Eswaran-Gray-Lorie-Traiger 1976 ; Berenson et al. 1995 ; Adya 1999 ; ARIES 1992 ; Bernstein 1976 ; 4NF et DK/NF ; Bayer-McCreight 1972 ; Extendible Hashing 1979 ; Linear Hashing 1980 ; Optimum BST 1971. Ce bloc suffit déjà à former un socle remarquablement durable en théorie relationnelle, transactionnel, optimisation et structures d'accès. ³²

Le **bloc moderne** à lire en second pour le contrepoint 2024-2026 est le suivant : la rétrospective 2024 sur l'évolution des modèles de données ; les surveys *Cloud-Native Databases* et *HTAP Databases* ; la synthèse 2025 sur l'optimisation réelle ; les travaux récents sur learned cardinality estimation, leurs gains, leurs limites et leurs risques ; les évaluations 2025-2026 sur learned indexes et learned optimizers ; enfin les travaux récents sur concurrence déterministe. Ce bloc n'annule pas le socle, il lui sert de banc d'essai contemporain. ³³

Les principales **limites** de ce corpus sont au nombre de trois. D'abord, certains classiques historiques majeurs ne sont plus librement exposés par l'éditeur en texte intégral HTML ; on doit parfois s'appuyer sur des pages d'éditeur, des reprints universitaires ou des résumés d'archives. Ensuite, le catalogue exhaustif des lois de réécriture dépend de la variante d'algèbre considérée, notamment dès qu'on sort de la sémantique en ensembles pour aller vers la sémantique en sacs, qui colle davantage à SQL. Enfin, les travaux 2025-2026 sur composants appris, indexes appris et optimiseurs appris sont très sérieux, mais ils ne doivent pas être confondus avec le niveau de stabilité conceptuelle du socle Codd-Selinger-Gray-Fagin-Bayer. ³⁴

Le document Markdown téléchargeable consolidant ce corpus est disponible ici : [corpus_recherche_sgbdr_2026.md](#)

- 1 5 8 32 <https://research.ibm.com/publications/a-relational-model-of-data-for-large-shared-data-banks>
<https://research.ibm.com/publications/a-relational-model-of-data-for-large-shared-data-banks>
- 2 21 <https://arxiv.org/abs/2101.01507>
<https://arxiv.org/abs/2101.01507>
- 3 13 <https://www.microsoft.com/en-us/research/publication/a-critique-of-ansi-sql-isolation-levels/?lang=fr-ca>
<https://www.microsoft.com/en-us/research/publication/a-critique-of-ansi-sql-isolation-levels/?lang=fr-ca>
- 4 24 <https://otexts.com/fpp3/>
<https://otexts.com/fpp3/>
- 6 9 <https://research.ibm.com/publications/access-path-selection-in-a-relational-database-management-system>
<https://research.ibm.com/publications/access-path-selection-in-a-relational-database-management-system>
- 7 <https://15445.courses.cs.cmu.edu/fall2025/notes/15-optimization1.pdf>
<https://15445.courses.cs.cmu.edu/fall2025/notes/15-optimization1.pdf>
- 10 <https://jimgray.azurewebsites.net/papers/thetransactionconcept.pdf>
<https://jimgray.azurewebsites.net/papers/thetransactionconcept.pdf>
- 11 22 <https://cs-people.bu.edu/mathan/reading-groups/papers-classics/histograms.pdf>
<https://cs-people.bu.edu/mathan/reading-groups/papers-classics/histograms.pdf>
- 12 <https://www.csd.uoc.gr/~hy460/pdf/p624-eswaran.pdf>
<https://www.csd.uoc.gr/~hy460/pdf/p624-eswaran.pdf>
- 14 ARIES: A Transaction Recovery Method Supporting Fine- ...
https://research.ibm.com/publications/aries-a-transaction-recovery-method-supporting-fine-granularity-locking-and-partial-rolls-backs-using-write-ahead-logging?utm_source=chatgpt.com
- 15 16 <https://dl.acm.org/doi/abs/10.1145/2213836.2213838>
<https://dl.acm.org/doi/abs/10.1145/2213836.2213838>
- 17 <https://forum.thethirdmanifesto.com/wp-content/uploads/asgarosforum/987737/00-efc-further-normalization.pdf>
<https://forum.thethirdmanifesto.com/wp-content/uploads/asgarosforum/987737/00-efc-further-normalization.pdf>
- 18 <https://research.ibm.com/publications/multivalued-dependencies-and-a-new-normal-form-for-relational-databases>
<https://research.ibm.com/publications/multivalued-dependencies-and-a-new-normal-form-for-relational-databases>
- 19 28 https://www.researchgate.net/profile/Bernhard-Thalheim/publication/221269408_Fundamentals_of_Cardinality_Constraints/links/549abad50cf2fedbc30e2f92/Fundamentals-of-Cardinality-Constraints.pdf
https://www.researchgate.net/profile/Bernhard-Thalheim/publication/221269408_Fundamentals_of_Cardinality_Constraints/links/549abad50cf2fedbc30e2f92/Fundamentals-of-Cardinality-Constraints.pdf
- 20 <https://www.kimballgroup.com/wp-content/uploads/2013/08/2013.09-Kimball-Dimensional-Modeling-Techniques11.pdf>
<https://www.kimballgroup.com/wp-content/uploads/2013/08/2013.09-Kimball-Dimensional-Modeling-Techniques11.pdf>
- 23 <https://15799.courses.cs.cmu.edu/spring2025/papers/15-learned/kim-sigmod2022.pdf>
<https://15799.courses.cs.cmu.edu/spring2025/papers/15-learned/kim-sigmod2022.pdf>
- 25 <https://dl.acm.org/doi/abs/10.1145/3715126>
<https://dl.acm.org/doi/abs/10.1145/3715126>

- 26 <https://link.springer.com/article/10.1007/BF00288683>
<https://link.springer.com/article/10.1007/BF00288683>
- 27 https://www.researchgate.net/publication/220225699_Extendible_Hashing_-_A_Fast_Access_Method_for_Dynamic_Files
https://www.researchgate.net/publication/220225699_Extendible_Hashing_-_A_Fast_Access_Method_for_Dynamic_Files
- 29 <https://link.springer.com/article/10.1007/BF00264289>
<https://link.springer.com/article/10.1007/BF00264289>
- 30 <https://epubs.siam.org/doi/10.1137/0201010>
<https://epubs.siam.org/doi/10.1137/0201010>
- 31 <https://arxiv.org/abs/1712.01208>
<https://arxiv.org/abs/1712.01208>
- 33 <https://db.cs.cmu.edu/papers/2024/whatgoesaround-sigmodrec2024.pdf>
<https://db.cs.cmu.edu/papers/2024/whatgoesaround-sigmodrec2024.pdf>
- 34 <https://chuzhe.me/assets/pdf/2022%20-%20WeTune-%20Automatic%20Discovery%20and%20Verification%20of%20Query%20Rewrite%20Rules.pdf>
<https://chuzhe.me/assets/pdf/2022%20-%20WeTune-%20Automatic%20Discovery%20and%20Verification%20of%20Query%20Rewrite%20Rules.pdf>